

# İSTANBUL TOPKAPI ÜNİVERSİTESİ

Mühendislik Fakültesi – Yazılım Mühendisliği Bölümü

FET312 – Derin Öğrenme

2025/26 Güz Dönemi

## NeiPalette

Nehir Sevil – 23040301072

*GitHub: <https://github.com/nehirsevil/Nei-Palette>*

# 1. Giriş

Moda ve giyim sektörü, görsel algının ve estetik değerlendirmenin en yoğun olduğu alanlardan biridir. Kullanıcılar giyim ürünlerini seçerken yalnızca ürünün işlevselliğini değil, aynı zamanda renk, stil ve kombin uyumunu da dikkate almaktadır. Özellikle dijital alışveriş platformlarının yaygınlaşmasıyla birlikte, kullanıcıların karşısına çıkan ürün çeşitliliği artmış ve bu durum doğru kombinlerin seçilmesini daha da zorlaştırmıştır.

Geleneksel öneri sistemleri çoğunlukla kullanıcıların geçmiş tercihleri, satın alma davranışları veya ürünler arasındaki benzerlikler üzerinden öneriler sunmaktadır. Ancak bu yaklaşımlar, estetik uyum ve renk ilişkileri gibi görsel açıdan kritik faktörleri yeterince dikkate alamamaktadır. Renk uyumu, büyük ölçüde insan algısına ve sezgisine dayalı bir kavram olduğu için kural tabanlı yöntemlerle modellenmesi zor bir problemdir.

Derin öğrenme, özellikle evrimsel sinir ağları (Convolutional Neural Networks – CNN) sayesinde görsel verilerden otomatik olarak anlamlı ve bağlamsal özellikler çıkarabilmektedir. Bu özellik, renk uyumu gibi karmaşık ve öznel problemlerin modellenmesinde önemli bir avantaj sağlamaktadır. CNN tabanlı modeller, yalnızca renk bilgisini değil, renklerin görsel bağlam içindeki dağılımını ve ilişkilerini de öğrenebilmektedir.

Bu proje kapsamında, üst ve alt giyim parçalarına ait görseller kullanılarak kombinlerin renk uyumu açısından değerlendirilmesini amaçlayan derin öğrenme tabanlı bir sınıflandırma sistemi geliştirilmiştir. Farklı derin öğrenme mimarileri kullanılarak elde edilen sonuçlar karşılaştırılmış ve sınırlı veri koşullarında bu mimarilerin davranışları analiz edilmiştir.

*Bu proje başlangıçta grup çalışması olarak planlanmış ve vize aşamasında bu doğrultuda ilerlenmiştir. Ancak proje sürecinin ilerleyen aşamalarında, grup çalışmasının sağlıklı biçimde sürdürülememesi ve sorumluluk paylaşımına ilişkin yaşanan belirsizlikler nedeniyle çalışmanın bireysel olarak devam ettirilmesi zorunlu hale gelmiştir. Bu nedenle final aşamasında sunulan rapor, vize raporunda yer alan bazı yöntemsel tercihlerden ve deneysel yaklaşımlardan farklılık göstermektedir. Final raporunda yer alan tüm modelleme, deneyler ve analizler, çalışmanın bireysel olarak yürütüldüğü süreçte yeniden tasarlanmış ve uygulanmıştır.*

## 2. Problemin Tanımı ve Motivasyon

Renk uyumu problemi, birden fazla rengin bir araya geldiğinde estetik açıdan kabul edilebilir bir bütün oluşturup oluşturmadığının belirlenmesini amaçlamaktadır. İnsanlar bu değerlendirmeyi çoğunlukla sezgisel olarak yapabilirse de, bu sezgiyi matematiksel ve algoritmik bir modele dönüştürmek oldukça zordur. Renklerin yalnızca sayısal değerlerden ibaret olmaması, aynı zamanda algısal ve bağlamsal özellikler taşıması bu problemin temel zorluklarından biridir.

Bu çalışmanın temel problemi, üst ve alt giyim parçalarına ait görseller kullanılarak oluşturulan bir kombinasyonun renk uyumu açısından uyumlu (positive) ya da uyumsuz (negative) olarak sınıflandırılmasıdır. Kullanılan veri setinde, kombin uyumuna ilişkin hazır etiketler bulunmadığından, problem tanımına uygun olarak veri seti manuel biçimde etiketlenmiştir. Bu durum, problemin denetimli öğrenme (supervised learning) yaklaşımıyla ele alınmasını mümkün kılmıştır.

Problemin bir diğerk zorluğu, kombin uyumunun sübjektif bir kavram olmasıdır. Aynı kombin farklı bireyler tarafından farklı şekillerde değerdendirilebilir. Bu nedenle çalışmanın amacı, evrensel bir “doğru kombin” tanımını oluşturmak değil; verilen etiketlere göre tutarlı bir sınıflandırma modeli geliştirmektir. Modelin başarımı, insan algısına dayalı olarak oluşturulan bu etiketlerle ne ölçüde örtüştüğü üzerinden değerdendirilmektedir.

Bu projenin motivasyonu, derin öğrenme tabanlı yöntemlerin sınırlı ve sübjektif etiketli veri koşullarında nasıl davrandığını incelemek ve farklı evrişimsel sinir ağı mimarilerinin aynı problem üzerindeki performanslarını karşılaştırmaktır. Bu doğrultuda, transfer öğrenme yaklaşımı kullanılarak eğitilen modellerin renk uyumu problemini öğrenme potansiyeli analiz edilmiştir.

### 3. İlgili Çalışmalar

Moda analizi ve giyim öneri sistemleri alanında yapılan çalışmalar incelendiğinde, derin öğrenme yöntemlerinin özellikle son yıllarda yaygın olarak kullanıldığını görülmektedir. Evrişimsel sinir ağları (CNN), giyim ürünlerinin sınıflandırılması, stil analizi, kıyafet eşleştirme ve görsel benzerlik tabanlı öneri sistemleri gibi birçok problemde başarılı sonuçlar ortaya koymuştur.

Bu alanda en yaygın kullanılan veri setlerinden biri olan DeepFashion ve DeepFashion2, kıyafet sınıflandırma, poz tahmini, segmentasyon ve stil analizi gibi farklı görevler için referans niteliğindedir. Ancak bu veri setleri doğrudan “kombin uyumu” veya “renk uyumu” etiketleri içermemektedir. Bu nedenle literatürde renk uyumu problemi çoğunlukla dolaylı yöntemlerle ele alınmaktadır.

Renk uyumu üzerine yapılan erken dönem çalışmalarda, görüntülerden renk histogramlarının çıkarılması, dominant renklerin belirlenmesi ve bu renkler arasındaki ilişkilerin istatistiksel ölçülerle modellenmesi yaygın bir yaklaşım olmuştur. Bu yöntemler renk bilgisini doğrudan kullanmalarına rağmen, renklerin görsel bağlam içindeki dağılımını ve yapısal ilişkilerini yeterince dikkate almamaktadır.

Son yıllarda transfer öğrenme tabanlı yaklaşımlar, sınırlı veri setleri üzerinde dahi tatmin edici performans elde edilmesini mümkün kılmıştır. ImageNet gibi büyük ölçekli veri setleri üzerinde önceden eğitilmiş CNN mimarilerinin, farklı problem alanlarına uyarlanarak kullanılması yaygın bir yöntem hâline gelmiştir. Bu projede de literatürdeki bu yaklaşımlar temel alınmış ve farklı derin öğrenme mimarileri renk uyumu problemi bağlamında karşılaştırmalı olarak değerdendirilmiştir.

### 4. Veri Seti

#### 4.1 Veri Seti Kaynağı


Bu çalışmada kullanılan veri seti, moda analizi alanında yaygın olarak kullanılan DeepFashion2 veri setindeki giyim ürünü görsellerinden türetilmiştir. DeepFashion2 veri seti, farklı giyim kategorilerine ait yüksek çözünürlüklü RGB formatında görseller içermektedir. Ancak bu veri seti doğrudan kombin uyumu veya renk uyumu etiketleri sağlamadığından, proje kapsamında problem tanımına uygun olacak şekilde yeni bir alt küme oluşturulmuştur. Veri seti yalnızca akademik ve eğitim amaçlı kullanılmıştır.

#### 4.2 Veri Seti Oluşturma ve Etiketleme

Kombin uyumu problemi DeepFashion2 veri setinde hazır etiketler içermediği için, üst ve alt giyim parçalarından oluşan kombinler manuel olarak oluşturulmuş ve etiketlenmiştir. Her kombin, renk uyumu açısından değerlendirilerek uyumlu (positive) veya uyumsuz (negative) olarak sınıflandırılmıştır. Bu etiketleme süreci insan değerlendirmesine dayalı olarak gerçekleştirilmiştir.

Oluşturulan veri seti toplam **40 kombin örneğinden** oluşmaktadır. Bu kombinlerin **20'si uyumlu (positive)**, **20'si uyumsuz (negative)** olarak etiketlenmiştir. Her kombin bir üst ve bir alt giyim görselinden oluştuğu için toplam görsel sayısı **80**'dir. Sınıf dağılımı dengeli olup her iki sınıf eşit sayıda örnek içermektedir.

Veri setindeki sınıf dağılımı Şekil-1 'de görünmektedir.



Şekil-1 Veri setindeki sınıf dağılımı (positive / negative)

#### 4.3 Veri Seti Bölünmesi

Veri seti, PyTorch kütüphanesinde yer alan `random_split` yöntemi kullanılarak eğitim ve test kümelerine ayrılmıştır. Bölünme işlemi sonucunda veri setinin **60 görseli eğitim**, **20 görseli test** setinde yer almıştır. Bu yaklaşım, modellerin eğitim ve değerlendirme süreçlerinin aynı veri dağılımı üzerinde gerçekleştirilmesini sağlamıştır.

**Tablo 1. Eğitim ve test kümelerindeki sınıf dağılımı**

Küme	Positive	Negative	Toplam
Eğitim	32	28	60
Test	11	9	20

#### 4.4 Veri Ön İşleme ve Görselleştirme

Tüm görseller model eğitiminden önce sabit bir giriş boyutuna yeniden ölçeklendirilmiş ve normalize edilmiştir. Eğitim sürecinde sınırlı veri miktarının olumsuz etkisini azaltmak amacıyla yatay çevirme ve rastgele kırpma gibi temel veri artırma (data augmentation) teknikleri uygulanmıştır. Uygulanan veri artırma işlemleri örnek sayısını artırmamakta, ancak modelin genelleme yeteneğini güçlendirmektedir.

### 5. Yöntem

Bu çalışmada, giyim kombinlerinin renk uyumu açısından sınıflandırılması problemi derin öğrenme tabanlı bir yaklaşım ile ele alınmıştır. Problem, iki sınıflı (uyumlu–uyumsuz) bir görüntü sınıflandırma problemi olarak modellenmiştir. Çalışma kapsamında transfer öğrenme yaklaşımı benimsenmiş ve iki farklı evrimsel sinir ağı mimarisi kullanılarak karşılaştırmalı bir analiz gerçekleştirilmiştir.

#### 5.1 Derin Öğrenme Yaklaşımı

Derin öğrenme tabanlı modeller, görsel verilerden otomatik olarak anlamlı özellikler çıkarabilme yetenekleri sayesinde renk uyumu gibi bağlamsal problemler için uygun bir çözüm sunmaktadır. Bu çalışmada, ImageNet veri seti üzerinde önceden eğitilmiş modeller kullanılarak transfer öğrenme uygulanmıştır. Böylece, sınırlı veri seti koşullarında modelin genelleme yeteneğinin artırılması hedeflenmiştir.

Her iki modelde de önceden eğitilmiş ağların evrimsel katmanları temel özellik çıkarıcı olarak kullanılmış, sınıflandırma işlemi için ise son katmanlar problem tanımına uygun şekilde yeniden düzenlenmiştir. Modeller, uyumlu (positive) ve uyumsuz (negative) kombinleri ayırt edecek şekilde eğitilmiştir.

#### 5.2 ResNet18 Mimarisi

Çalışmada kullanılan ilk model ResNet18 mimarisidir. ResNet mimarisi, derin ağlarda karşılaşılan gradyan kaybolması problemini azaltmak amacıyla artık bağlantılar (residual connections) kullanmaktadır. Bu özellik, daha derin ağların daha kararlı şekilde eğitilmesini mümkün kılmaktadır. (He et al., 2016)

ResNet18 modeli, ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklarla başlatılmıştır. Modelin son tam bağlantılı (fully connected) katmanı, iki sınıflı çıktı üretecek şekilde yeniden düzenlenmiştir. Eğitim sürecinde çapraz entropi (cross-entropy) kayıp fonksiyonu kullanılmış ve model parametreleri Adam optimizasyon algoritması ile güncellenmiştir.

#### 5.3 EfficientNet-B0 Mimarisi

İkinci model olarak EfficientNet-B0 mimarisi kullanılmıştır. EfficientNet mimarileri, modelin derinliği, genişliği ve giriş çözünürlüğünü dengeli bir şekilde ölçeklendiren bir yapı sunmaktadır. Bu sayede, daha az parametre ile yüksek performans elde edilmesi hedeflenmektedir. (Tan & Le, 2019)

EfficientNet-B0 modeli de ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklarla kullanılmıştır. ResNet18 modelinde olduğu gibi, son sınıflandırma katmanı problem tanımına uygun olarak iki sınıflı çıkış verecek şekilde yeniden yapılandırılmıştır. Model, aynı eğitim ve değerlendirme prosedürleri kullanılarak eğitilmiş ve test edilmiştir.

#### 5.4 Eğitim Süreci ve Hiperparametreler

Her iki modelin eğitim sürecinde PyTorch kütüphanesi kullanılmıştır. Eğitimde çapraz entropi kayıp fonksiyonu tercih edilmiş, optimizasyon için Adam algoritması kullanılmıştır. Hiperparametreler manuel olarak belirlenmiş ve sınırlı veri seti göz önünde bulundurularak kısa eğitim süreleri tercih edilmiştir. Modellerin performansı, eğitim sürecinden sonra ayrılmış test veri seti üzerinde değerlendirilmiştir.

## 6. Deneysel Kurulum

Bu çalışmada gerçekleştirilen tüm deneyler Python programlama dili kullanılarak geliştirilmiş ve PyTorch derin öğrenme kütüphanesi ile yürütülmüştür. Modellerin eğitimi ve değerlendirilmesi aynı deneysel ortamda gerçekleştirilerek karşılaştırmanın adil olması sağlanmıştır.

#### 6.1 Eğitim Ortamı

Deneyler, masaüstü bilgisayar ortamında gerçekleştirilmiştir. Model eğitimi sırasında CPU tabanlı hesaplama kullanılmıştır. Küçük ölçekli veri seti nedeniyle eğitim süreleri kısa tutulmuş ve donanımsal kısıtlar deney sürecini olumsuz etkilememiştir.

#### 6.2 Veri Hazırlama ve Yükleme

Görseller model eğitiminden önce sabit bir giriş boyutuna yeniden ölçeklendirilmiş ve normalize edilmiştir. PyTorch Dataset ve DataLoader yapıları kullanılarak veri yükleme işlemleri gerçekleştirilmiştir. Veri seti, random\_split yöntemi ile eğitim ve test kümelerine ayrılmış ve her iki model için de aynı veri bölünmesi kullanılmıştır. Bu sayede modellerin performansları doğrudan karşılaştırılabilir hâle getirilmiştir.

#### 6.3 Eğitim Parametreleri

Her iki modelin eğitim sürecinde çapraz entropi (cross-entropy) kayıp fonksiyonu kullanılmıştır. Optimizasyon için Adam algoritması tercih edilmiştir. Eğitim süreci sınırlı sayıda epoch boyunca gerçekleştirilmiş ve overfitting riskini azaltmak amacıyla uzun süreli eğitimden kaçınılmıştır. Hiperparametreler manuel olarak belirlenmiş ve her iki model için aynı ayarlar kullanılarak deneysel tutarlılık korunmuştur.

#### 6.4 Değerlendirme Yaklaşımı

Model performansları, eğitim tamamlandıktan sonra ayrılmış test veri seti üzerinde değerlendirilmiştir. Değerlendirme sırasında accuracy, precision, recall, F1-score ve ROC-

AUC metrikleri kullanılmıştır. Ayrıca modellerin sınıflandırma davranışlarını daha ayrıntılı incelemek amacıyla ROC eğrileri oluşturulmuştur.

## 7. Performans Değerlendirmesi ve Sonuçlar

Bu bölümde, çalışmada kullanılan ResNet18 ve EfficientNet-B0 modellerinin test veri seti üzerindeki performansları karşılaştırmalı olarak değerlendirilmiştir. Değerlendirme sürecinde accuracy, precision, recall, F1-score ve ROC-AUC metrikleri kullanılmıştır. Ayrıca modellerin sınıflandırma davranışlarını daha ayrıntılı analiz edebilmek amacıyla ROC eğrileri incelenmiştir.

### 7.1 Genel Performans Karşılaştırması

Her iki modelin test veri seti üzerindeki genel performans sonuçları Tablo 2’de sunulmuştur. Tablo incelendiğinde, ResNet18 modelinin EfficientNet-B0 modeline kıyasla daha dengeli bir performans sergilediği görülmektedir. Özellikle accuracy ve ROC-AUC metrikleri açısından ResNet18 modeli, rastgele sınıflandırma seviyesinin üzerinde sonuçlar üretmiştir.

**Tablo 2. Modellerin genel performans karşılaştırması**

Model	Accuracy	Precision	Recall	F1-score	ROC-AUC
<b>ResNet18</b>	<b>0.50</b>	<b>0.56</b>	<b>0.45</b>	<b>0.50</b>	<b>0.505</b>
EfficientNet-B0	0.45	0.50	0.273	0.353	0.384

### 7.2 Sınıf Bazlı Performans Analizi

Modellerin sınıf bazlı performanslarını daha ayrıntılı incelemek amacıyla precision, recall ve F1-score değerleri uyumlu (positive) ve uyumsuz (negative) sınıflar için ayrı ayrı değerlendirilmiştir. Sınıf bazlı sonuçlar Tablo 3’de gösterilmektedir.

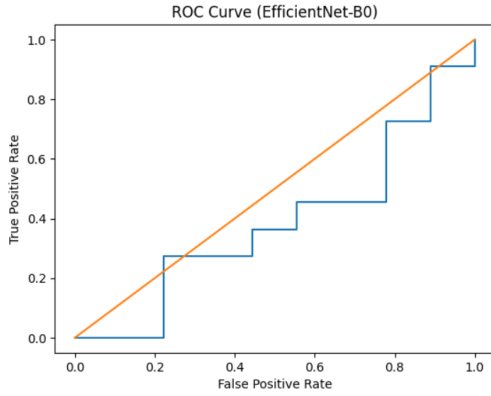
**Tablo 3. Sınıf bazlı performans sonuçları**

Sınıf	Model	Precision	Recall	F1-score
positive	<b>ResNet18</b>	<b>0.56</b>	<b>0.45</b>	<b>0.50</b>
positive	EfficientNet-B0	0.50	0.273	0.353
negative	ResNet18	0.45	0.56	0.50
negative	<b>EfficientNet-B0</b>	<b>0.429</b>	<b>0.667</b>	<b>0.522</b>


Sonuçlar incelendiğinde, EfficientNet-B0 modelinin uyumsuz (negative) sınıf için daha yüksek recall değerine sahip olduğu, ancak uyumlu (positive) sınıf için daha düşük F1-score ürettiği görülmektedir. ResNet18 modeli ise her iki sınıf için daha dengeli bir performans sergilemiştir.

### 7.3 ROC Eğrileri ve AUC Analizi

Modellerin ayırt edicilik performanslarını değerlendirmek amacıyla ROC eğrileri çizilmiş ve ROC-AUC değerleri hesaplanmıştır. ResNet18 modeli yaklaşık **0.505** ROC-AUC değeri ile rastgele sınıflandırma seviyesinin biraz üzerinde bir performans göstermiştir. EfficientNet-B0 modeli ise yaklaşık **0.384** ROC-AUC değeri ile daha düşük bir ayırt edicilik performansı sergilemiştir. ROC eğrileri, ResNet18 modelinin genel olarak daha tutarlı bir karar mekanizmasına sahip olduğunu göstermektedir.



Şekil 3. EfficientNet-B0 ROC eğrisi



Şekil 2. ResNet18 ROC eğrisi

## 8. Tartışma

Bu çalışmada elde edilen deneysel sonuçlar incelendiğinde, her iki modelin de sınırlı bir performans sergilediği görülmektedir. Bu durum, kullanılan veri setinin yapısı ve problem tanımının doğası göz önünde bulundurulduğunda beklenen bir sonuçtur. Kombin uyumu problemi, nesnel bir doğruluk ölçütüne sahip olmayan ve büyük ölçüde insan algısına dayalı bir problem olduğu için, model performanslarının belirli bir seviyenin üzerine çıkması zorlaşmaktadır.

Veri setinin küçük ölçekli olması, modellerin genelleme yeteneğini sınırlayan temel faktörlerden biridir. Toplam 40 kombin örneği ve 80 görsel içeren veri seti, derin öğrenme modellerinin karmaşık görsel ilişkileri öğrenmesi için oldukça sınırlıdır. Bu durum özellikle EfficientNet-B0 gibi daha karmaşık mimarilerde belirginleşmiş ve modelin bazı metriklerde düşük performans göstermesine neden olmuştur.

EfficientNet-B0 modelinin bazı sınıflar için yüksek recall değerleri üretmesine rağmen genel performansının düşük kalması, modelin karar eşiklerinde tutarsız davranabildiğini göstermektedir. Buna karşılık ResNet18 modeli, daha basit bir mimariye sahip olmasına rağmen daha dengeli bir performans sergilemiştir. Bu durum, küçük veri setleri üzerinde daha sade mimarilerin zaman zaman daha kararlı sonuçlar üretebildiğini göstermektedir.

ROC-AUC değerlerinin her iki model için de düşük çıkması, modellerin sınıflar arasındaki ayırt ediciliğinin sınırlı olduğunu ortaya koymaktadır. Özellikle EfficientNet-B0 modelinin ROC eğrisinin diyagonalin altında kalması, modelin bazı karar eşiklerinde sınıfları ters yönde ayırt ettiğini göstermektedir. Bu sonuç, veri setinin subjektif etiket yapısı ve örnek sayısının azlığı ile doğrudan ilişkilidir.



Bu çalışmanın amacı, yüksek doğruluk elde etmekten ziyade, derin öğrenme tabanlı farklı mimarilerin renk uyumu problemi üzerindeki davranışlarını incelemek ve karşılaştırmaktır. Bu bağlamda elde edilen sonuçlar, sınırlı ve sübjektif etiketli veri koşullarında model seçiminin ve mimari karmaşıklığın performans üzerindeki etkilerini açıkça ortaya koymaktadır.

## 9. Sonuç ve Gelecek Çalışmalar

Bu çalışmada, üst ve alt giyim parçalarından oluşan kombinlerin renk uyumu açısından sınıflandırılmasını amaçlayan derin öğrenme tabanlı bir sistem geliştirilmiştir. DeepFashion2 veri setinden türetilmiş ve manuel olarak etiketlenmiş küçük ölçekli bir veri seti kullanılarak, transfer öğrenme yaklaşımı ile ResNet18 ve EfficientNet-B0 mimarileri karşılaştırmalı olarak değerlendirilmiştir.

Deneyisel sonuçlar, her iki modelin de sınırlı veri koşullarında kısıtlı bir performans sergilediğini göstermektedir. Performans metrikleri incelendiğinde, ResNet18 modelinin EfficientNet-B0 modeline kıyasla daha dengeli ve tutarlı sonuçlar ürettiği gözlemlenmiştir. Özellikle accuracy, F1-score ve ROC-AUC metrikleri açısından ResNet18 modeli, rastgele sınıflandırma seviyesinin üzerinde bir performans sergilemiştir. EfficientNet-B0 modeli ise bazı sınıflar için yüksek recall değerleri üretmesine rağmen genel ayırt edicilik açısından daha düşük bir performans göstermiştir.

Elde edilen sonuçlar, veri setinin sınırlı boyutu ve kombin uyumu etiketlerinin sübjektif yapısının model performansını doğrudan etkilediğini ortaya koymaktadır. Bu durum, renk uyumu gibi estetik ve algısal problemlerin derin öğrenme ile modellenmesinde veri kalitesinin ve etiket tutarlılığının kritik önem taşıdığını göstermektedir.

Gelecek çalışmalarda, daha büyük ve çeşitli bir veri seti oluşturularak model performanslarının artırılması hedeflenmektedir. Ayrıca, etiketleme sürecinin birden fazla kişi tarafından gerçekleştirilmesi veya yarı-denetimli öğrenme yaklaşımlarının kullanılması, sübjektif etiket etkisinin azaltılmasına katkı sağlayabilir. Bunun yanı sıra, farklı mimariler ve çoklu girdi yapıları kullanılarak kombin uyumunun daha kapsamlı biçimde modellenmesi mümkündür.

## Kaynakça

1. He, K., Zhang, X., Ren, S., & Sun, J. (2016).  
*Deep residual learning for image recognition*.  
Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770–778.
2. Tan, M., & Le, Q. (2019).  
*EfficientNet: Rethinking model scaling for convolutional neural networks*.  
Proceedings of the International Conference on Machine Learning (ICML), 6105–6114.
3. Goodfellow, I., Bengio, Y., & Courville, A. (2016).  
*Deep Learning*.  
MIT Press.
4. Paszke, A., Gross, S., Massa, F., et al. (2019).  
*PyTorch: An imperative style, high-performance deep learning library*.  
Advances in Neural Information Processing Systems (NeurIPS), 8026–8037.
5. Chollet, F. (2018).  
*Deep learning with Python*.  
Manning Publications.